

ATANOR

그래프 네이티브 · 로컬 우선 · 환각하지 않는 AI

사업계획서 — Primer 배치 지원

“외부 거대언어모델 없이, GPU 없이, 출처를 증명하며 답하는 AI”

작성일: 2026년 6월 · 본 문서의 성능 수치는 자체 실측값입니다 (부록 출처 참조)
팀/재무/투자요청 항목의 [] 는 창업자가 채울 자리입니다.

1. 한 줄 요약 (Executive Summary)

ATANOR는 외부 거대언어모델(LLM)을 쓰지 않고, 명시적 지식 그래프와 실시간 검색으로 답하는 로컬 우선(local-first) AI입니다. 답은 그래프에서 파생되거나 공개 웹(위키백과 등)에서 그대로 인용되며, 모든 답에 출처와 추론 증명서가 붙습니다. 근거가 없으면 지어내지 않고 “모르겠다”라고 합니다.

자체 실측 핵심 지표

지표	ATANOR (실측)	프런티어 LLM (공개 추정)
환각률(거짓 단정)	~0% (존재하지 않는 개체 함정 0/N 날조)	프런티어 LLM: ~1.5–6% (검색 시), 미검색 시 더 높음
출처/인용	100% (모든 웹 답변에 실제 URL)	기본 0%, RAG여도 <100%
답변 시 GPU	0 (모델 추론 없음)	수백 W의 GPU
질문당 에너지	~0.001 Wh	~0.3–3 Wh
모델 가중치 / VRAM	0 GB / 0 VRAM	2.4–40 GB 가중치 / 4–48 GB VRAM
설치 용량	핵심 의존성 ~11 MB + 그래프	torch/CUDA ~4–5 GB + 가중치
프라이버시	로컬 우선 (사적 메모리 비업로드)	클라우드 전송

→ ATANOR는 신뢰성(환각 0·완전 출처), 비용/에너지(GPU 0), 프라이버시(로컬), 설치 경량성에서 구조적 우위를 가집니다. 대가는 지식 커버리지와 일반 추론 깊이가 프런티어 LLM보다 낮다는 점이며, 이는 설계상의 정직한 트레이드오프입니다.

2. 문제 (Problem)

거대언어모델(LLM)은 강력하지만, 신뢰가 핵심인 현장에서는 네 가지 구조적 한계로 도입이 막힙니다.

- 환각 — 그럴듯한 거짓을 자신 있게 만들어냅니다. 사실 검증이 중요한 업무에서 치명적입니다.
- 비용·에너지 — 질문마다 GPU 추론(질문당 ~0.3~3 Wh, 수백 W). 대규모/엣지 배포에 부담입니다.
- 프라이버시 — 프롬프트가 클라우드로 전송됩니다. 데이터 외부 유출이 금지된 산업에는 부적합합니다.
- 감사 불가능 — “왜 그렇게 답했는가”를 증명할 출처·근거 사슬이 없습니다.

결과적으로 금융·의료·법률·공공·국방 등 규제·고신뢰 영역과 온디바이스/엣지·프라이버시 민감 환경에서 LLM 도입의 결정적 장벽이 됩니다. 이 시장은 ‘똑똑함’보다 ‘틀리지 않음·증명 가능성·안전함’을 더 원합니다.

3. 솔루션 & 제품 (Solution & Product)

ATANOR는 기억·출처·검색·복구·공개지식 교환을 하나의 원격 모델 호출 안에 숨기지 않고, 전부 명시적인 그래프 시스템으로 둡니다.

두뇌 구조

- 베이스 브레인 — 사용자 데이터 없이도 기본 개념을 설명하는 로컬 시드 지식 그래프
- 클라우드 브레인 — 공개 웹에서 검증된 개념을 누적 학습하는 공개 그래프 (개인정보 비업로드)
- 로컬 브레인 — 대화에서 얻은 사용자 정보를 기기 안에만 쌓는 사적 메모리
- 서피스 브레인 — 그래프의 근거를 자연스러운 문장으로 실현(realization)
- CGSR 라우팅·그라운딩 — 질문을 적절한 두뇌/검색으로 분기, 근거에 묶어 답 생성

핵심 기능

- 추출형 웹 그라운딩 — 근거가 없으면 공개 웹에서 검색해 문장을 인용하고 출처를 표시, 새 개념은 그래프에 누적
- 결정론적 다단계 추론 — “A와 B 중 누가 먼저 태어났어?”(검색→검색→비교), “프랑스의 수도의 인구는?”(연쇄 2-hop) 등을 LLM 없이
- 자기 모델 — 자신이 무엇이고 어떻게 작동하는지 일관되게 설명
- 추론 증명서 — 모든 답이 근거·도출 방식·보증(외부 LLM 미사용 등)을 함께 출력 → 감사 가능
- 살아있는 UI — 파티클 ‘구슬’이 답하고, 출처 문서를 지니 효과로 띄우는 등 에이전트가 화면을 자율 제어
- 자율 누적 학습 + AGORA — 밤사이 공개 웹을 정직하게 학습하고, 에이전트 커뮤니티(AGORA)와 상호작용

4. 핵심 차별점 — 측정된 사실 (Why we are different)

아래는 마케팅 수사가 아니라 실제 측정값입니다 (자체 벤치마크 하니스 + 하드웨어 계측, 부록 참조).

정직성 & 신뢰

- 환각률 ~0%: 존재하지 않는 가짜 개체로 함정을 깔아도 전부 '모른다'고 abstain (날조 0건)
- 인용 정밀도 100%: 모든 웹 답변이 답을 추출한 바로 그 출처 URL을 보유
- 완전한 출처추적: 모든 답에 추론 증명서 — LLM은 '왜'를 증명하지 못함

효율 & 배포

- 답변 시 서버 GPU 0 · 질문당 ~0.001 Wh (프런티어 LLM 대비 ~100~1000배 적은 에너지)
- 모델 가중치 0 · VRAM 0 · 핵심 의존성 ~11 MB → GPU 없는 기기에서도 구동
- 로컬 우선 프라이버시 — 사적 메모리는 기기 밖으로 나가지 않음

정직한 한계: 그래프+검색 구조이므로 지식 커버리지가 프런티어 LLM보다 좁고, 일반 다단계 추론 깊이가 아직 얕습니다(현재 비교·연쇄 추론 단계). 캐시되지 않은 사실은 인터넷이 필요합니다.

5. 시장 (Market)

타깃 고객

- 규제·고신뢰 산업: 금융(컴플라이언스·리서치), 의료, 법률, 공공·국방 — 환각/유출이 허용되지 않는 영역
- 온디바이스 / 엣지 AI: GPU 없이 도는 경량 AI가 필요한 단말·임베디드·오프그리드
- 프라이버시 우선 기업: 데이터를 외부 LLM에 보낼 수 없는 조직 (온프레미스)
- 저전력·저자원 환경: 에너지/하드웨어 비용이 결정적인 시장

시장 규모 (방향성)

전 세계 엔터프라이즈 AI 시장은 빠르게 성장 중이며, 그 안에서 프라이빗/온프레미스·신뢰가능 AI와 온디바이스 AI 수요가 별도 축으로 커지고 있습니다. ATANOR는 '가장 똑똑한 모델' 경쟁이 아니라 '틀리면 안 되고, 밖으로 나가면 안 되고, 싸게 돌아야 하는' 세그먼트를 정조준합니다. [구체 TAM/SAM/SOM 수치 및 출처 — 창업자 보강]

6. 비즈니스 모델 (Business Model)

수익 모델	대상	근거/강점
온프레미스 라이선스	규제산업 엔터프라이즈	데이터 외부 유출 불가 요구를 정조준; 로컬 구동이 곧 제품 가치
per-seat / 사용량 SaaS	팀·중소기업	GPU 비용 0 → 낮은 운영비로 가격 경쟁력
임베디드/엣지 라이선스	단말·하드웨어 제조사	0 VRAM~11MB로 기기 내장 가능
도메인 그래프 팩	수직 산업(의료/법률 등)	Graph Hub로 도메인 지식 큐레이션 판매
컨트리뷰터 클라우드(AGORA)	장기·네트워크 효과	다수 사용자 PC에 거주하는 에이전트 공용 학습

핵심: 추론에 GPU가 들지 않아 단위 운영비(COGS)가 극히 낮습니다. 이는 가격·마진·엣지 배포 모두에서 구조적 이점입니다.

7. 경쟁 우위 / 해자 (Competition & Moat)

경쟁군	그들의 강점	ATANOR의 우위
프런티어 LLM (OpenAI·Anthropic·Google)	지식·일반 추론 폭	환각 0·완전 출처·감사·프라이버시·에너지/비용
로컬 LLM (Llama-ollama)	오프라인·소유권	환각(소형도 발생)·수GB 가중치·VRAM 필요 → 우리는 0
RAG/검색 벤더	검색+생성 결합	외부 LLM 의존 제거 → 비용·프라이버시·인용 정밀도

해자는 단일 기능이 아니라 '정직성 + 경량성 + 프라이버시'의 결합입니다. LLM 진영이 이를 따라오려면 근본 아키텍처(생성형 가중치 모델)를 바꿔야 합니다. 더불어 도메인 그래프 자산과 AGORA 네트워크 효과가 시간이 지날수록 누적 방어력을 만듭니다.

8. 로드맵 & 비전 (Roadmap)

단기 (0-6개월)

- 작동 프로토타입 → 클로즈드 베타; 규제산업 1-2곳 PoC
- 공개 벤치마크 100문항 + 에너지/footprint 백서 공개 (신뢰 마케팅)

중기 (6-18개월)

- 추론 코어 심화 — PHFE(위상 홀로그래픽 폴딩: 파동간섭 + 결정론적 폴딩)로 일반 다단계 추론 강화
- 도메인 그래프 팩(의료·법률·금융) 상용화; 온프레미스 배포 패키지
- 분산 컨트리뷰터 클라우드(AGORA) v1 — 다수 노드 공용 학습

장기 비전

‘프로그램 안에 사는 정직한 생명체’ — 모든 기기에서 GPU 없이 돌고, 환각하지 않으며, 모든 답을 증명하는 신뢰 가능한 AI 인프라. LLM이 ‘가장 똑똑한 답’을 겨룰 때, ATANOR는 ‘가장 믿을 수 있고 가장 가벼운 답’의 표준이 됩니다.

9. 현재 상태 / 트랙션 (Traction)

- 작동하는 풀스택 프로토타입: 대시보드 UI + FastAPI 엔진 + 5개 두뇌 + 자율 학습 루프
- 결정론적 다단계 추론(비교·연쇄) 구현 및 단위테스트 통과
- 자체 측정 벤치마크 하니스(67문항) — 환각 0%·인용 100% 재현
- 에너지·footprint 하드웨어 실측 백서 (GPU 0, ~0.001 Wh/질문, 가중치 0)

단계: 프로토타입/시드. 매출·계약·파일럿 등 정량 트랙션은 창업자가 보강 — []

10. 팀 (Team)

[창업자/공동창업자 이름 · 역할 · 핵심 이력 · 왜 우리가 이걸 해낼 수 있는가(Founder-Market Fit)를 채워주세요.]

- [대표 — 성명 / 배경 / 강점]
 - [기술 — 성명 / 배경 / 강점]
 - [자문·초기 멤버 — 있다면]
-

11. 투자 요청 & 자금 사용 (The Ask)

[라운드/금액/밸류 및 자금 사용처를 채워주세요. 아래는 참고용 골격입니다.]

사용처	비중(예시)	목적
제품·엔지니어링	[%]	추론 코어·온프레미스 패키지·도메인 그래프
GTM·파일럿	[%]	규제산업 PoC·초기 고객 확보
인프라·운영	[%]	벤치마크 공개·보안/컴플라이언스 인증

목표(예시): []개월 내 []개 유료 파일럿 / 베타 사용자 []명 / 벤치마크 공개로 신뢰 포지셔닝 확립.

부록 — 측정 출처 (Appendix)

본 문서의 모든 성능 수치는 자체 코드/계측에서 재현 가능합니다:

- 벤치마크 하니스: packages/answer_quality/factual_qa_benchmark.py (67문항, 환각·인용·정답·지연)
- 벤치마크 비교: docs/ATANOR_BENCHMARK_COMPARISON.md · docs/ATANOR_VS_LLMS_NUMBERS.md
- 에너지: docs/ATANOR_ENERGY_EFFICIENCY.md (RTX 5080 계측)
- 설치 용량: docs/ATANOR_FOOTPRINT.md (가중치 0·VRAM 0~11MB)
- 추론 코어: comparison_reasoner.py · chained_reasoner.py

※ 프런티어/로컬 LLM 수치는 공개 모델카드·리더보드(MMLU·GSM8K·Vectara HHEM·ALCE·TruthfulQA) 추정값으로, 서로 다른 테스트셋이므로 방향성 비교입니다. 외부 모델을 동일 셋으로 직접 구동하지 않았습니다(설계상 외부 LLM 미사용).